

Implementacija vmesnika možgani računalnik za klasifikacijo med dvema motoričnima aktivnostima

Matic Isovski

Univerza v Ljubljani
Fakulteta za računalništvo in informatiko
E-pošta: mi6568@student.uni-lj.si

Povzetek

V sklopu 3. projekta pri predmetu *Komunikacija človek računalnik*, je bil implementiran vmesnik možgani računalnik za klasifikacijo med dvema motoričnima aktivnostima. Predstavljena je podatkovna zbirka EEG zapisov, na kateri testiramo implementirane metode pridobivanja značilk (Skupni prostorski vzorci) ter klasifikatorja (Linearna in kvadratična diskriminantna analiza). Predstavljeni so pridobljeni rezultati na enem od subjektov iz podatkovne zbirke ter primerjava uspešnosti z uporabo različnih časovnih dolžin signalnih blokov, kjer smo dosegli 88% klasifikacijsko točnost.

1 Uvod

V nalogi implementiramo vmesnih možgani računalnik za klasifikacijo med dvema motoričnima aktivnostima. Z namenom izločanja značilk v prostoru komponent signale najprej filtriramo s prostorskim filtrom Skupnih prostorskih vzorcev. Metoda nam omogoča ekstrakcijo značilk, ki nam projicirajo večkanalne EEG signale v prostor komponent, tako da maksimizira varianco signalov enega stanja in simultano minimizira varianco signalov drugega stanja. Dobljene signale v prostoru komponent nato filtriramo s pasovno prepustni KEO filtrom (8.0 - 13.0 Hz) ter uporabimo funkciji Var in log za generacijo značilk v prostoru komponent. Za klasifikacijo uporabimo klasifikatorja z linearno diskriminantno analizo ter kvadratično diskriminantno analizo.

2 Podatkovna zbirka

Pri implementaciji in testiranju smo si pomagali z zbirko EEG posnetkov EEG Motor Movement/Imagery Dataset [1]. Zbirka znaša preko 1500 posnetkov za 109 subjektov. Za vsak subjekt je 14 eno/dvo-minutnih posnetkov s 64 kanali (elektrodami). Posnetki zajemajo signale ob različnih motoričnih aktivnostih kot tudi zamišljanje le teh.

3 Metode

Nad posnetki, ki vsebujejo zamišljanje aktivnosti leve in desne roke smo najprej izvedli izločanje značilk z metodo skupnih prostorskih vzorcev. Dobljene signale v prostoru komponent smo nato filtrirali z izbranim spektralnim filtrom. Za generacijo značilk v prostoru komponent smo

uporabili še funkciji Var in log. Za klasifikacijo smo uporabili klasifikator z linearno diskriminantno analizo ter klasifikator z kvadratično diskriminantno analizo. Vmesnik je bil realiziran v večparadigmskem jeziku Matlab [2].

3.1 Skupni prostorski vzorci

Algoritem skupnih prostorskih vzorcev (SPV) je metoda ekstrakcije značilnosti, ki uporablja prostorske filtre za čim večje razlikovanje dveh razredov in se ga pogosto uporablja za ekstrakcijo funkcij v sistemih BCI, ki temeljijo na EEG, za motorične posnetke [3, 4, 5].

$$\tilde{X}(n) = W^{-1}S(n) \quad (1)$$

SPV najde transformacijo, ki maksimizira varianco signalov enega stanja in simultano minimizira varianco signalov drugega stanja. SPV značilke so potem dane z

$$f(n) = \log(\text{Var}(WX)) \quad (2)$$

3.2 LDA in QDA

Linearna Diskriminantna Analiza (LDA) privzema, da so razredi linearno ločljivi ter definira linearno diskriminantno funkcijo, ki predstavlja hiperravnino v prostoru značilk za ločevanje razredov [6]. Odločitvena (diskriminantna) funkcija je predstavljena kot linearna kombinacija p komponent vektorja značilk x ,

$$y = x^T w - b \quad (3)$$

kjer je w vektor normale na optimalno hiperravnino, b pa prag.

$$w = (\Sigma_1 + \Sigma_2)^{-1}(\mu_2 - \mu_1) \quad (4)$$

$$b = w^T(\mu_2 + \mu_1)/2 \quad (5)$$


LDA predpostavlja, da so vzorci obeh razredov normalno porazdeljeni ter da sta Gauss-ovi distribuciji večdimenzionalnih vektorjev značilk obeh razredov karakterizirani s srednjima vrednostima μ_i in kovariančnima matrikama Σ_i . LDA ima še dodatno poenostavljeno predpostavko homoskedastičnosti:

$$\Sigma_0 = \Sigma_1 = \Sigma \quad (6)$$

Kvadratična diskriminantna analiza je podobna LDA, le da ne upošteva predpostavke o homoskedastičnosti.


4 Rezultati

Za testiranje smo izbrali subjekt S053. Uporabili smo posnetke 4, 8 ter 12, ki vsebujejo zamišljanje aktivnosti leve in desne roke. Signali so bili razdeljeni v bloke dolžine 4 sekund, za "učne" intervale, smo pa vzeli prve tri. Na sliki 1 lahko vidimo povprečje intervalov zamišljanja za desno roko. Za izračun matrike W pri metodi skupnih



Slika 1: Povprečje intervalov za desno roko

prostorskih vzorcev smo uporabili učne povprečne intervale, saj nam da to bolj optimalne rezultate, kot če bi matriko izračunali na osnovi vseh signalov. Dobljene signale v prostoru komponent, smo nato filtrirali s pasovno prepustnim KEO filtrom (8.0 - 13.0 Hz). Na sliki 2 lahko vidimo diagram raztrosa, ki ga dobimo po izračunu značilk. Videti je, da nam je taka konfiguracija dokaj lepo ločitev primerov obeh razredov. Za klasifikacijo smo



Slika 2: Diagram raztrosa

uporabili LDA in QDA, rezultati so prikazani v tabeli 1. Rezultate smo predstavili kot mero specifičnosti, senzitivnosti, točnost klasifikacije ter površino pod krivuljo (AUC). Dosegli smo dobre rezultate. Eksperimentirali smo še z dolžino blokov signalov ter spremljali, kako le ta vpliva na rezultate. V tabeli 2 lahko vidimo točnost klasifikacije ter površino pod krivuljo za LDA in QDA, glede

Klasifikator	Sp	Se	Točnost	AUC
LDA	80.95	90.91	86.05	86.36
QDA	80.95	95.45	88.37	92.64

Tabela 1: Rezultati obeh klasifikatorjev

na dolžino blokov (v sekundah). Hitro lahko vidimo, da

	LDA		QDA	
Interval	Točnost	AUC	Točnost	AUC
1.0s	51.16	61.26	53.49	58.44
1.5s	53.49	58.44	67.44	67.10
2.0s	83.72	90.69	83.72	91.99
2.5s	88.37	92.86	88.37	92.42
3.0s	88.37	93.94	88.37	93.94
3.5s	88.37	92.86	88.37	92.21
4.0s	86.05	86.36	88.37	92.64

Tabela 2: Primerjava rezultatov z bloki različnih dolžin

dosegamo boljše rezultate, kadar so bloki dolžine $> 2s$. Največja razlika je med 1.5 sekunde in 2 sekunde. Razlike znotraj intervala $[2s, 4s]$ pa vidimo, da skoraj ni. Prav tako je zanimiva podobnost klasifikacijske točnosti med LDA in QDA za vse primere. Največjo razliko vidimo pri bloku dolžine 1.5 sekunde ter bloku dolžine 4 sekund.

5 Diskusija

Nad rezultati smo bili pozitivno presenečeni in zadovoljeni. Na izbranem subjektu smo dosegli visoko klasifikacijsko točnost. Podobne rezultate smo dosegli tudi nad drugimi subjekti, ki niso bili predstavljeni. Vidimo pa tudi možnost izboljšave oz. povečanja zaupanja v rezultate. Poleg LDA in QDA (ki sta dosegla zelo podobne rezultate), bi lahko uporabili še kak drug klasifikator ter primerjali še te rezultate.

Literatura

- [1] Goldberger, A., Amaral, L., Glass, L., Hausdorff, J., Ivanov, P. C., Mark, R., ... & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation [Online]. 101 (23), pp. e215–e220.
- [2] <https://www.mathworks.com/products/matlab.html>
- [3] Franc Jager, Predobdelava in izločanje časovnih ter prostorskih značilk I, Komunikacija človek računalnik
- [4] Franc Jager, Predobdelava in izločanje časovnih ter prostorskih značilk II, Komunikacija človek računalnik
- [5] Franc Jager, Spektralna analiza, parametrično modeliranje in časovno frekvenčne predstavitve
- [6] Franc Jager, Klasifikacije in VMR s strojnimi učenjem